同一批财报：什么问题该建库，什么问题该微调

《人工智能与数据分析》W3 作业·方向 A ｜ 语料：15 家 A 股家电公司 2026 年半年度报告全文（2,588 页 / 310 万字 / 3,852 张表 → 切 5,876 块）｜ 检索：本地 Qwen3-Embedding-0.6B 向量 + jieba/BM25 双路 ｜ 回答：DeepSeek，逐句带出处 ｜ 2026-10-16

一、做了什么

从巨潮资讯网下载 15 家家电公司（美的、格力、海尔智家、海信家电、TCL智家、长虹美菱、苏泊尔、九阳、老板电器、华帝、小熊、新宝、石头科技、科沃斯、飞科）的 2026 年半年报全文；按课件口径切块（**800 字 / 重叠 120 字 / 句末收尾**，每块带**公司·章节·页码·块序号**四标签，表格按行列还原、每块重复表头）；建向量 + BM25 双索引，做成可提问、答案带出处的网页；出 10 道题（4 道跨公司）逐题记录召回与对错。

5/10 → 8/10
严格答对的题数：基本混合 → 抽词+分组

5/5
单公司事实题在两种模式下全对

10/10
回答里每一句都标了出处编号

二、10 道题的结果（逐题召回明细见 results/逐题记录.md）

题	类型	基本混合	抽词+分组	错在哪（两种模式的失败点）
1	单公司·表格直取	对	对	单位被样板行过滤误删，模型不敢补单位
2	单公司·同比	对	对	主动区分营业收入 / 营业总收入
3	单公司·口径陷阱	对	对	材料只解释同比、未解释与净利润的差 → 如实说明
4	单公司·非财务	半对	对	基本混合误判“境外收入未披露”（附注里有）
5	单公司·口语长问题	对	对	铺垫埋了 2 家干扰公司仍命中：公司名是强锚
6	单公司·多子问题	②错	对	三问被两家公司“平均”，研发段落一块没进前 8
7	跨公司·单指标比较	错	仅格力	三家的销售费用表都没进前 8 → 答“材料未提供”
8	跨公司·全景（风险）	4/15 家	5/15 家	答案散在十几家之间，top-8 装不下（课件同款结论）
9	跨公司·全景（政策）	4 家	5 家	政策名词字面固定，是跨公司题里最稳的一类
10	跨公司·比较+归因	结论错	对	基本混合漏了格力→“海尔最慢”；抽词后自行算出格力 −8.14%

三、三类问题的分界（来自上面这张表的真实数据）

- **点状事实 → 建库就够，而且很稳。**“某家公司的某个科目是多少、在哪一页说的”，答案落在 1–3 块里：单公司题 **5/5 全对**，两种检索模式没有区别，每句都能点回原文页。**不需要微调**——知识每季度都变，权重里背下来的数字下个报告期就是错的。
- **跨公司比较与全景 → 建库也能做，但要额外做检索侧工程。**一句话写三家公司时，向量把三家“平均”成一个问句；一家块多就把 8 个名额占满（第 7、10 题基本混合全错，第 10 题还给出错误结论）。把问题先抽成关键词、再按公司分组保底召回之后，**5/10 → 8/10**（第 6、10 题救回，第 4 题多找到附注里的分地区收入）。**决定成败的是切块、表头、分词、分组这些工程细节，不是换 embedding**：本次两个致命 bug 都在工程层（数字被分词器丢掉、正则里混进退格符）。
- **只有“习惯”才值得微调。**10 道题的答案里数字全部来自检索，模型一次也没有编造；真正每次都要重复的是**作答的格式与口径习惯**——“先结论后依据、每句带出处、金额统一成亿元并注明合并/母公司口径”。这些不随财报更新、却每次都要模型照做，正是课件里 SFT 的正例。

一句话结论：同一批财报，**“谁在哪一页说了什么”的事实适合建库**——知识会更新、答案要溯源、一次检索就能答对（单公司题 5/5，跨公司题加检索侧工程补到 8/10）；**而“每次都用同一套格式和口径作答”的习惯才适合微调**——它不随财报更新，却是最该写进权重的东西。

附·踩到并已修的四个坑：①页眉页脚是“万能块”（每页重复的“公司名+附注+金额单位+页码”与任何问题都像），按“出现在该公司 15% 以上块里”判为样板行删掉，丢弃 828 块——副作用是“金额单位为千元”这类有用信息也被删，第 1 题因此丢单位；②分词器把数字丢了（“90,642,783”“5129627933.54”因含逗号/小数点被判为标点过滤），全库带小数点的金额都进不了 BM25，这是财报检索的致命伤；③修②时脚本把正则里的 `\b` 写成了 `\x08`，那行 `re.sub` 静默失效，白修一轮；④思考模式吃光 max_tokens，首跑 6 道题返回空回答（推理 token 也算在 max_tokens 里），上限提到 8192 后正常。

代码与数据：`财报问答库/`（scripts/01–10 全流程脚本、web/index.html 页面、results/ 逐题记录+召回评测+原始问答日志）。财报 PDF 不入库，`01_download.py` 一条命令重下；密钥只在 .env（已 gitignore）。